Reporte Lab 03 — Arbitraje estadístico con cointegración y filtros de Kalman

Equipo 7: Jerónimo Rojas y Raúl Zanatta · Microestructura y Sistemas de Trading, ITESO · Nov 7, 2026 · @Jeronimo Rojas

Resumen ejecutivo

La estrategia opera la reversión a la media de un portafolio de cuatro utilities eléctricas de Estados Unidos (DUK, SO, AEP y XEL). En 15 años ganó 20.2% neto de costos (1.3% anual), con Sharpe de 0.37 y drawdown máximo de 6.7%.

- **Selección.** De 66 grupos evaluados en seis sectores, solo cinco aprobaron el embudo de cointegración, todos de utilities. Se eligió el grupo de cuatro activos: Johansen identifica una relación (traza 55.7 contra 47.9 al 95%), con spread estacionario (ADF p = 0.0002) y vida media de 24 días.
- **Filtros.** El filtro de Kalman 1 adapta los pesos del vector día a día; el filtro 2 estima en tiempo real la media y la dispersión del spread y produce un z-score sin look-ahead.
- **Estabilidad.** Con los pesos fijos de Johansen el spread deja de ser estacionario en validación (p = 0.054); con los pesos de Kalman sigue siéndolo en prueba y validación (p = 0.011 y 0.002).
- **Resultados.** El Sharpe pasa de 0.41 en entrenamiento a 0.32 en prueba y 0.30 en validación, sin colapso fuera de muestra. Las comisiones consumen 26% de la ganancia bruta.

Conclusión. La relación de equilibrio es real pero débil y cambia con el tiempo: el Johansen móvil solo la detecta en 19% de las ventanas de tres años. No observamos sobreajuste de parámetros, pero con diez operaciones fuera de muestra el resultado no es estadísticamente distinto de cero y el rendimiento no supera la tasa libre de riesgo. El trabajo demuestra el método; la estrategia necesita más evidencia fuera de muestra y un filtro que detecte cuándo se pierde la cointegración antes de llevarla a producción (sección 11.4).

1. Objetivo y alcance

El objetivo es construir una estrategia de arbitraje estadístico sobre un grupo de activos cointegrados y sostener, con cifras propias, si la relación de equilibrio encontrada es estructural o un artefacto de haber probado muchos grupos.

El proyecto es **Nivel A**: un solo grupo de cuatro activos, número que corresponde a 2 × n con n = 2 integrantes. La sección 3.7 (Risk Parity entre varios grupos) se omite por indicación del profesor; por lo mismo no aplican la figura 9 ni la parte de Nivel B de la prueba 4.

El flujo, acordado con el profesor, es: vector de Johansen → normalización → filtro de Kalman 1 (pesos dinámicos) → spread → filtro de Kalman 2 (media y dispersión) → z-score normalizado → umbrales de entrada y salida → backtest con costos. Los "residuales normalizados" de la sección 3.6 son la salida normalizada del filtro 2.

Parámetro	Valor
Activos	DUK, SO, AEP, XEL (utilities eléctricas de EE.UU.)
Periodo	1-nov-2011 a 30-oct-2026, diario (15 años)
Partición	60 / 20 / 20, cronológica
Capital inicial	$1,000,000; 80% asignado a la posición
Comisión	0.125% por pata, a la entrada, a la salida y en rebalanceos
Préstamo	0.25% anual sobre el nocional corto, devengo diario

2. Datos

Se usan 3,771 días hábiles de precios de cierre ajustados por dividendos y splits (Yahoo Finance, `yfinance` con `auto_adjust=True`), sin un solo dato faltante ni duplicado. Los precios se guardan en `data/prices.csv` para que el pipeline no dependa de la disponibilidad de Yahoo.

Universo. Duke Energy (DUK), Southern Company (SO), American Electric Power (AEP) y Xcel Energy (XEL) son utilities reguladas: sus tarifas las fija un regulador estatal, sus ingresos son estables y los cuatro precios responden a los mismos factores comunes (tasas de interés, costo del gas natural y del carbón, inversión en red). Esa es la justificación económica de una tendencia estocástica común, y es nuestra defensa frente al problema de pruebas múltiples (sección 3).

Limpieza. Los huecos aislados de hasta 3 días se rellenan hacia adelante, nunca hacia atrás, para no usar información futura; en esta muestra no hubo ninguno. Todos los modelos trabajan con log-precios, de modo que los pesos se interpretan en términos porcentuales.

Partición. Todo parámetro (vector de Johansen, Q, R, φ, umbrales) se estima solo con entrenamiento. Prueba y validación se recorren después, día por día, con los parámetros congelados.

Partición	Desde	Hasta	Días	Contexto de mercado
Entrenamiento (60%)	1-nov-2011	27-oct-2020	2,262	Tasas bajas; incluye la caída de marzo de 2020
Prueba (20%)	28-oct-2020	26-oct-2023	754	Inflación y subida de tasas de 2022
Validación (20%)	27-oct-2023	30-oct-2026	755	Tasas altas y demanda eléctrica de centros de datos

Orden de integración. La cointegración exige que cada serie sea I(1). La prueba ADF en entrenamiento no rechaza raíz unitaria en niveles y la rechaza en primeras diferencias para los cuatro activos.

Activo	ADF p en log-niveles	ADF p en diferencias	Orden
DUK	0.686	< 0.001	I(1)
SO	0.881	< 0.001	I(1)
AEP	0.777	< 0.001	I(1)
XEL	0.963	< 0.001	I(1)

La figura 1 muestra las cuatro series con las tres particiones marcadas.

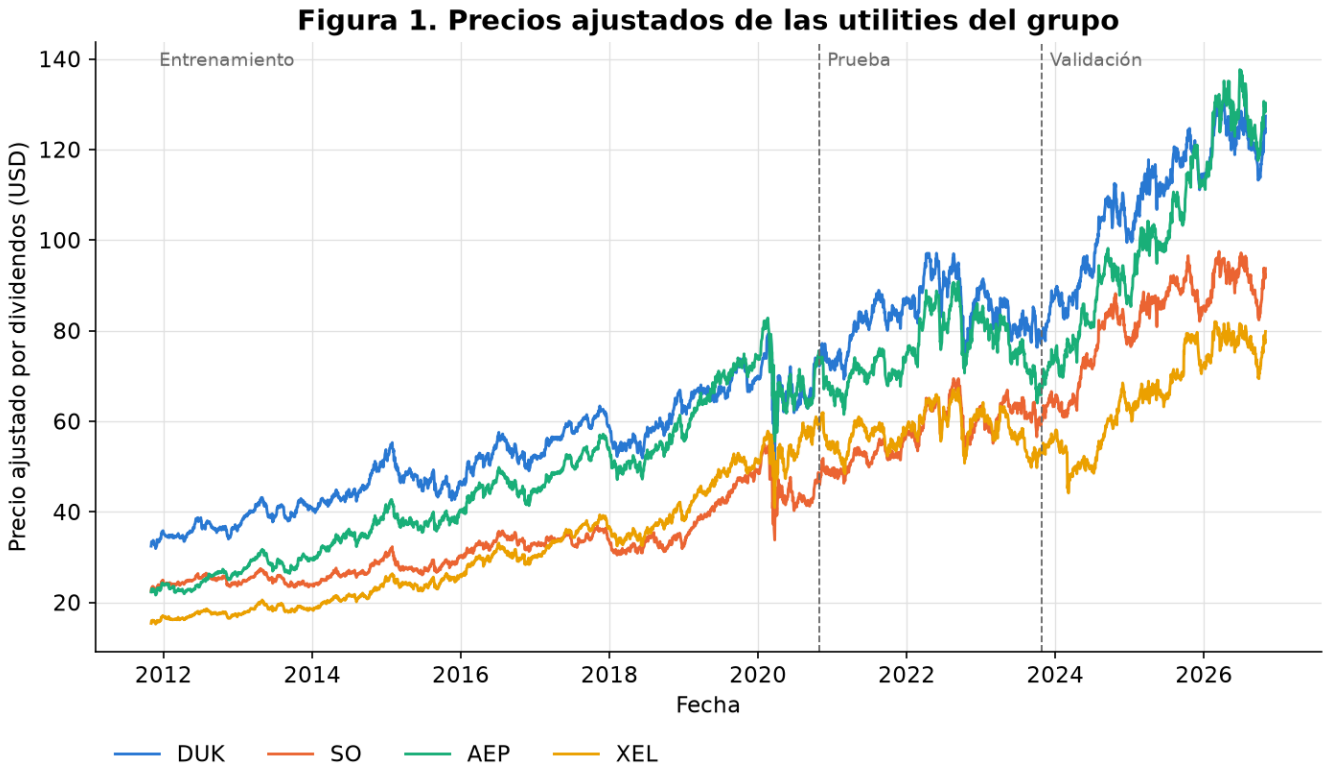


Figura 1. Precios ajustados de los cuatro activos, 2011–2026, con las particiones de entrenamiento, prueba y validación.

3. Selección del grupo

El grupo final es DUK-SO-AEP-XEL, con vector normalizado $\beta = (1, 0.181, -0.614, -0.099)$. Fue elegido entre 66 grupos de seis sectores mediante un embudo de cinco etapas, ejecutado solo con datos de entrenamiento.

3.1 Embudo de selección

1. **Universo.** Seis sectores de cuatro activos cada uno, con un factor económico común; cada sector aporta sus 11 subgrupos de 2 a 4 activos.
2. **Correlación.** Mediana de la correlación móvil de 252 días de los log-retornos de cada par; el grupo pasa si el promedio supera 0.7. Se usan retornos y no precios para evitar correlaciones espurias por tendencia. Es solo una heurística.
3. **Engle-Granger.** Regresión OLS de cada activo contra los demás y ADF sobre el residual; el grupo pasa si alguna orientación tiene $p < 0.05$ (valores críticos de MacKinnon). Es un pre-filtro permisivo.
4. **Johansen.** Con constante (`det_order = 0`) y rezagos del VECM = p − 1, con p elegido por BIC en un VAR en niveles. El rango se determina con la traza al 95%; el grupo pasa si el rango es al menos 1.

5. **Validación del spread.** El spread $S = \beta^T \ln P$ del primer eigenvector debe ser estacionario (ADF $p < 0.05$) y tener vida media entre 5 y 60 días, para que haya suficientes operaciones y cada una cierre en un plazo razonable.

Sector	Factor común	Grupos	Fuera por correlación	Fuera por Engle-Granger	Fuera por Johansen	Fuera por spread	Aprobados
Utilities (DUK, SO, AEP, XEL)	Tarifas reguladas y tasas	11	0	6	0	0	**5**
Petroleras (XOM, CVX, COP, EOG)	Precio del crudo	11	5	6	0	0	0
Ferrocarriles (UNP, CSX, NSC, CNI)	Volumen de carga	11	7	2	1	1	0
Bancos (JPM, BAC, C, WFC)	Curva de tasas y crédito	11	0	10	1	0	0
Consumo básico (KO, PEP, PG, CL)	Demanda inelástica	11	11	0	0	0	0
ETF de tecnología (XLK, VGT, IYW, IGM)	Mismas empresas subyacentes	11	0	11	0	0	0
Total		**66**	**23**	**35**	**2**	**1**	**5**

El universo inicial eran las petroleras; ningún grupo cointegró (Engle-Granger $p > 0.44$ y vidas medias de 77 a 205 días). Por eso se evaluaron los otros cinco sectores con el mismo embudo y se reporta la búsqueda completa en `artifacts/universe_search.csv`.

3.2 Grupos probados dentro de utilities

Grupo	Engle-Granger p	Traza ($r \leq 0$)	Valor crítico 95%	Rango	ADF p del spread	Vida media (días)	Resultado
DUK-SO-AEP-XEL	0.038	55.7	47.9	1	0.0002	24.0	**Elegido**
DUK-SO-AEP	0.012	40.8	29.8	1	0.0004	24.2	Aprobado
DUK-AEP-XEL	0.011	34.8	29.8	1	0.0005	25.9	Aprobado

Grupo	Engle-Granger p	Traza (r ⩽ 0)	Valor crítico 95%	Rango	ADF p del spread	Vida media (días)	Resultado
DUK-SO-XEL	0.050	30.2	29.8	1	0.0014	37.1	Aprobado
DUK-AEP	0.003	26.2	15.5	1	0.0005	26.0	Aprobado (mejor par)
SO-AEP-XEL	0.102	22.6	29.8	0	0.0032	54.5	Fuera por Engle-Granger
DUK-XEL	0.068	15.5	15.5	0	0.0118	56.4	Fuera por Engle-Granger
SO-XEL	0.129	14.2	15.5	0	0.0435	59.4	Fuera por Engle-Granger
DUK-SO	0.416	8.2	15.5	0	0.1738	139.2	Fuera por Engle-Granger
SO-AEP	0.524	7.9	15.5	0	0.3014	96.5	Fuera por Engle-Granger
AEP-XEL	0.463	7.9	15.5	0	0.1320	123.1	Fuera por Engle-Granger

Criterio de elección. Entre los aprobados de tres o cuatro activos se elige el de menor vida media: el grupo de cuatro (24.0 días) gana por poco al de tres (24.2), y además usa los cuatro activos que corresponden a 2 × n. El par DUK-AEP se conserva solo como referencia.

3.3 Prueba de Johansen del grupo final

H_0	Eigenvalor	Traza	Crítico 95%	Crítico 99%	Máx. eigenvalor	Crítico 95%	¿Rechaza al 95%?
r ⩽ 0	0.0145	55.66	47.85	54.68	33.07	27.59	Sí (ambas)
r ⩽ 1	0.0071	22.59	29.80	35.46	16.09	21.13	No
r ⩽ 2	0.0029	6.50	15.49	19.93	6.48	14.26	No
r ⩽ 3	0.0000	0.02	3.84	6.63	0.02	3.84	No

Ambos estadísticos coinciden en **una sola relación de cointegración** (r = 1). Por eso hay un solo vector candidato, el del mayor eigenvalor, que es la combinación más reversiva, y no aplica la tabla comparativa entre columnas del eigenvector.

Normalización y signo. El vector se divide entre la pata de mayor valor absoluto en entrenamiento, DUK, que queda en +1. Así el spread es S_t = ln P_DUK + 0.181 ln P_SO − 0.614 ln P_AEP − 0.099 ln P_XEL. Un spread alto significa que DUK y SO están caros frente a AEP y XEL.

Validación. El spread es estacionario en entrenamiento (ADF p = 0.0002) y su vida media, $-\ln 2 / \lambda$ con λ la pendiente de la regresión de ΔS_t sobre S_{t-1}, es de 24.0 días.

3.4 Pruebas múltiples

Con 66 grupos al 5% se esperan unos 3.3 falsos positivos por puro azar, así que cinco aprobados no prueban nada por sí solos. Tres hechos apuntan a una relación real:

- Los cinco aprobados están en un solo sector; en los otros cinco sectores aprobaron 0 de 55. Los falsos positivos al azar aparecerían dispersos.
- Los cinco aprobados comparten activos (DUK aparece en todos) y vidas medias parecidas (24 a 37 días), como se espera de una misma relación vista desde subconjuntos.
- La traza del grupo final rechaza también al 99% (55.7 contra 54.7).

La evidencia no es abrumadora: con corrección de Bonferroni (0.05 / 66 = 0.00076) solo DUK-AEP pasa Engle-Granger, y el grupo de cuatro rebasa el crítico del 99% por apenas un punto. La sección 6 revisa si la relación se sostiene en el tiempo.

4. Filtro de Kalman 1: pesos dinámicos

El filtro 1 actualiza cada día los pesos del vector de Johansen con la información disponible hasta ese día. Con $Q = 10^{-8}$ los pesos se mueven despacio: β_SO pasa de 0.181 a 0.177 en todo el entrenamiento y a 0.141 al final de la muestra (figura 3).

Figura 3. Evolución del vector de pesos $\hat{\beta}_t$ (filtro de Kalman 1; DUK normalizado en +1)

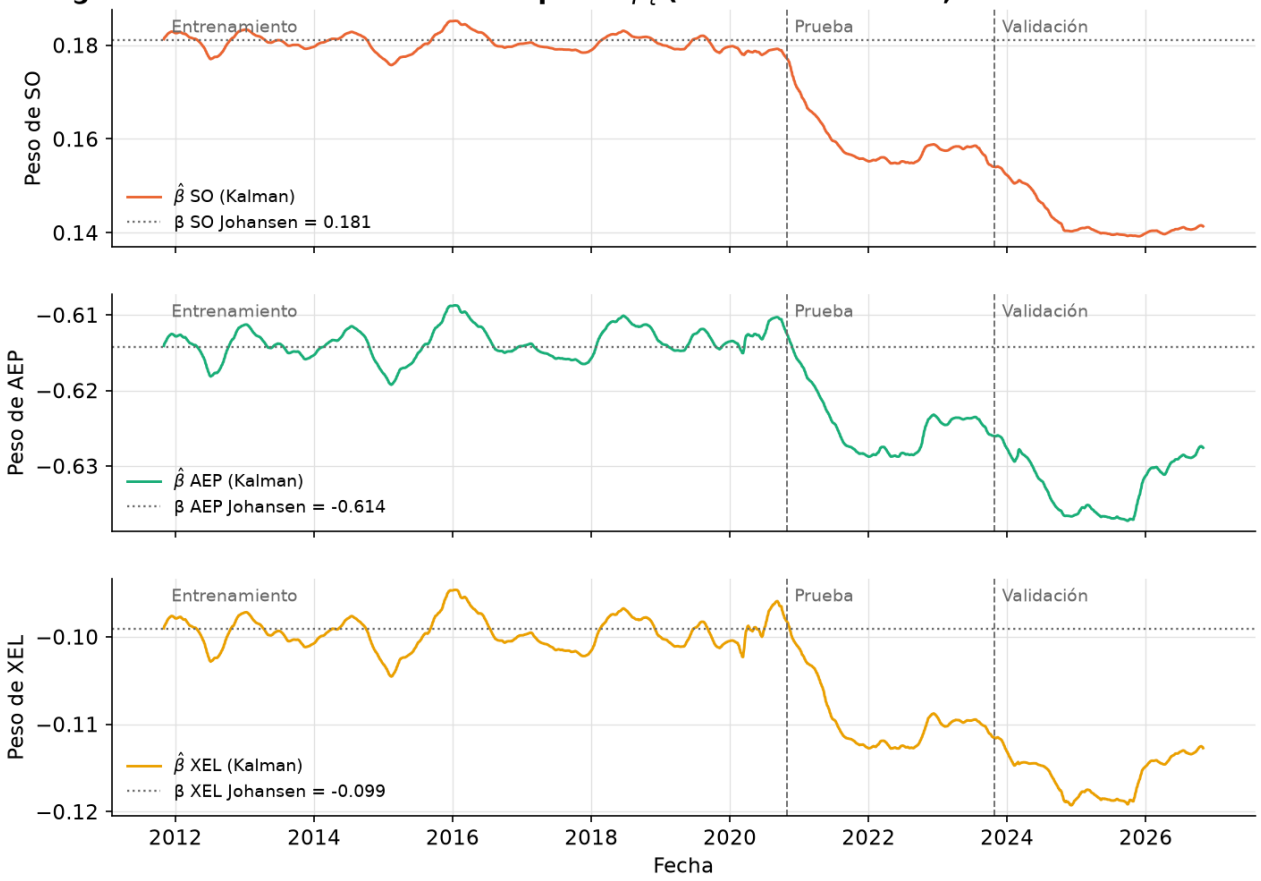


Figura 3. Pesos del vector estimados por el filtro 1, una línea por activo; DUK fijo en +1 por la normalización.

4.1 Proceso de modelado de 6 pasos (Powell)

1. **Problema.** Decidir con qué pesos se combina el portafolio cada día. Johansen da un vector fijo estimado con 2011–2020, pero la relación cambia: con el vector fijo el spread deja de ser estacionario en validación (p = 0.054).
2. **Estado.** $x_t = (c_t, \beta_SO,t, \beta_AEP,t, \beta_XEL,t)$. El peso de DUK queda fijo en +1 por la normalización, que fija la escala y el signo; c_t es el nivel de equilibrio del spread.
3. **Transición.** Caminata aleatoria (A = I): los pesos pueden cambiar, pero despacio.
4. **Observación.** El log-precio de DUK se explica con los otros tres; reordenando, el spread es $S_t = c_t + v_t$, así que el ruido de observación es justamente la desviación del equilibrio que se quiere operar.
5. **Regla de decisión.** La decisión es la estimación de los pesos de cada día; la política es la actualización de Kalman, una política de función analítica (PFA) con parámetros θ = (Q, R). El spread de la señal se calcula con los pesos **prior** (antes de ver el precio de hoy), para que los pesos con que se mide la desviación de hoy no dependan de ella.
6. **Aprendizaje.** Ecuaciones de predicción y actualización de Kalman (abajo).

$$
\begin{aligned}
x_t &= x_{t-1} + w_t, & w_t &\sim N(0, Q), \quad Q = 10^{-8} I \\
y_t = \ln P_{DUK,t} &= C_t\, x_t + v_t, & v_t &\sim N(0, R), \quad R = 1.136\times10^{-3} \\
C_t &= \left(1,\; -\ln P_{SO,t},\; -\ln P_{AEP,t},\; -\ln P_{XEL,t}\right)
\end{aligned}
$$

$$
\begin{aligned}
\hat x_{t|t-1} &= \hat x_{t-1|t-1}, & P_{t|t-1} &= P_{t-1|t-1} + Q \\
\tilde y_t &= y_t - C_t \hat x_{t|t-1}, & S_t &= C_t P_{t|t-1} C_t^\top + R \\
K_t &= P_{t|t-1} C_t^\top S_t^{-1}, & \hat x_{t|t} &= \hat x_{t|t-1} + K_t \tilde y_t, \quad P_{t|t} = (I - K_t C_t) P_{t|t-1}
\end{aligned}
$$

En las ecuaciones de Kalman S_t denota la varianza de la innovación; cuando se habla del spread se dice explícitamente "spread S_t".

4.2 Los 5 elementos del modelo

Elemento	Filtro 1
Variable de estado	Creencia sobre los pesos: media y covarianza del día anterior, ($\hat{x}_{t-1}$, P_{t-1})
Variable de decisión	Pesos estimados $\hat{x}_t$ y el spread calculado con los pesos prior
Información exógena	Log-precios del día siguiente, ln P_{t+1}
Función de transición	Ecuaciones de predicción y actualización de Kalman
Función objetivo	Minimizar el error cuadrático de predicción E[Σ $\tilde{y}_t^2$]; en el sistema completo, Q se juzga por su efecto en la estrategia (4.4)

4.3 Ganancia de Kalman

La varianza de la innovación es $S_t \approx 1.161 \times 10^{-3}$: $R = 1.136 \times 10^{-3}$ es ruido de observación y $C_t P_t|_{t-1} C_t^\top \approx 2.5 \times 10^{-5}$ es incertidumbre sobre los pesos. El filtro atribuye cerca de **2% de cada sorpresa a un cambio en los pesos y 98% a una desviación del spread**.

El 26 de septiembre de 2022 la innovación fue −0.0421: DUK cerró 4.2% por debajo de lo que predecían los pesos. Con K(β_SO) = −0.00177, el peso de SO cambió solo −0.00177 × (−0.0421) = +0.000075. Una ganancia pequeña significa que una desviación grande se trata como oportunidad de arbitraje, no como un cambio en la relación. Las ganancias de los pesos son negativas porque en C_t los log-precios entran con signo menos; lo que importa es su magnitud, entre 0.0015 y 0.0019 (figura 5).

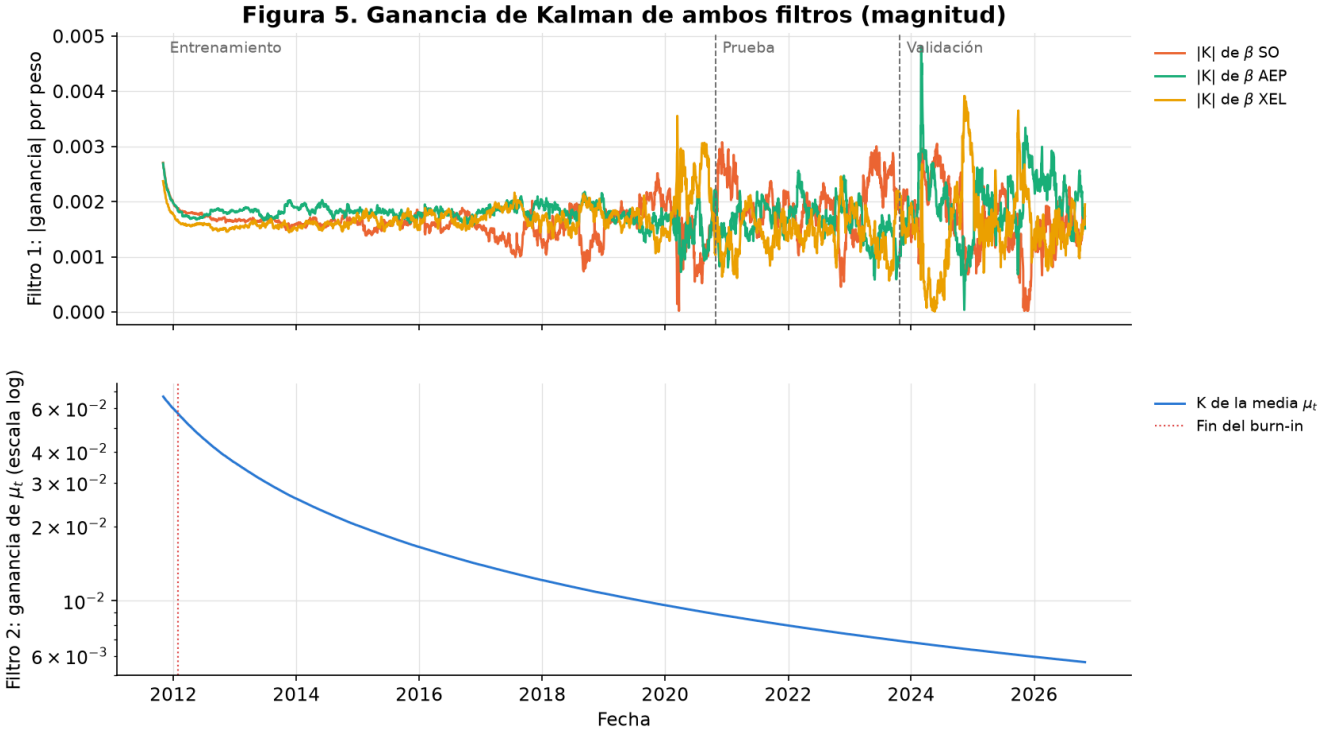


Figura 5. Magnitud de la ganancia de Kalman de los pesos (filtro 1) y de la media latente (filtro 2) en el tiempo.

4.4 Selección de Q y R, inicialización y burn-in

- **R = 1.136 × 10⁻³**, la varianza del spread de Johansen en entrenamiento: cuánto se desvía normalmente el portafolio de su equilibrio.
- **Q = 10⁻⁸ · I, fijada por diseño.** Por máxima verosimilitud siempre ganaban las Q grandes: con pesos que se mueven rápido el filtro "explica" cada desviación moviendo los pesos, y la reversión desaparece (vida media del spread de 98 a 293 días). La causa es que el modelo supone v_t ruido blanco y el spread real es autocorrelado. La razón Q/R ≈ 8.8 × 10⁻⁶ deja que los pesos sigan solo cambios estructurales lentos.
- **Q fuera del grid search.** Optimizada junto con los umbrales de trading, se elegía Q = 10⁻⁹: Sharpe de entrenamiento de 0.70 contra 0.41, pero con spread no estacionario fuera de muestra (ADF p = 0.24 en prueba) y Sharpe de 0.20 en prueba. Es sobreajuste, y por eso Q se fijó antes del backtest; la comparación se reporta ex post en `artifacts/q_sensitivity.csv`.

- **Inicialización:** $\hat{x}_0$ = (media del spread de Johansen en entrenamiento, 0.181, −0.614, −0.099) y $P_0 = 10^{-6} \cdot I$, confianza alta en el vector de Johansen.
- **Burn-in:** 60 días hábiles, unas cuatro vidas medias, hasta el 30 de enero de 2012; no se opera antes.
- **Estabilidad de la normalización:** la prueba `tests/test_normalization.py` verifica que el peso de DUK se mantiene en +1 y que los demás conservan escala y signo entre reestimaciones consecutivas.

4.5 Ejemplo numérico (22 al 28 de septiembre de 2022)

Se eligieron los días en que el z-score cruza −2 durante la caída de las utilities por la subida de tasas. Los números los genera `python main.py` en `artifacts/worked_example_filter1.csv`.

Fecha	y_t = ln P_DUK	Predicción con pesos prior	Innovación	Varianza S_t	K(β_SO)	β_SO prior → posterior	β_AEP posterior	β_XEL posterior	Spread
22-sep	4.49609	4.52109	−0.02499	0.0011617	−0.00188	0.155445 → 0.155492	−0.628004	−0.112247	1.88743
23-sep	4.48678	4.51383	−0.02705	0.0011616	−0.00185	0.155492 → 0.155542	−0.627959	−0.112208	1.88537
26-sep	4.45872	4.50085	−0.04213	0.0011613	−0.00177	0.155542 → 0.155616	−0.627886	−0.112147	1.87028
27-sep	4.43341	4.48200	−0.04859	0.0011610	−0.00184	0.155616 → 0.155706	−0.627808	−0.112077	1.86379
28-sep	4.44645	4.48484	−0.03839	0.0011612	−0.00191	0.155706 → 0.155779	−0.627748	−0.112022	1.87396

En todos los días y componentes se cumple posterior = prior + K × innovación, con error máximo de 10^{-10}. La innovación coincide con la desviación del spread respecto a su nivel de equilibrio (1.8703 − 1.9124 = −0.0421 el 26 de septiembre): DUK cayó más de lo que justificaban SO, AEP y XEL.

5. Filtro de Kalman 2: media latente y z-score

El filtro 2 estima en tiempo real el nivel de equilibrio μ_t y la dispersión σ_t del spread del filtro 1, y los convierte en un z-score causal. Fuera de muestra sus innovaciones normalizadas son ruido blanco con varianza cercana a uno (0.99 en prueba y 1.08 en validación), como exige el modelo.

5.1 Proceso de modelado de 6 pasos (Powell)

1. **Problema.** Decidir cada día si el spread está lejos de su equilibrio. Para eso hay que estimar, sin look-ahead, su nivel μ_t y su dispersión σ_t.
2. **Estado.** La media latente μ_t, estimada con Kalman, y la varianza σ_t^2, actualizada en paralelo con un promedio exponencial (EWMA) de las innovaciones.
3. **Transición.** μ_t sigue una caminata aleatoria con $Q = 10^{-10}$; la varianza, un EWMA con $\lambda = 0.97$.
4. **Observación.** El spread revierte como un AR(1) alrededor de μ_t. Como $\mu_t \approx \mu_{t-1}$, la observación $y_t = S_t - \varphi S_{t-1}$ queda lineal en el estado, con $\varphi = 0.9563$ (vida media de 15.5 días) y $R = 6.515 \times 10^{-5}$.
5. **Regla de decisión.** El z-score se calcula con los estadísticos **prior**, antes de actualizar con el dato del día. Normalizar con la media posterior usaría la observación de hoy para juzgarse a sí misma y sesgaría el z-score hacia cero. Las reglas de entrada y salida (sección 7) se aplican sobre este z_t.
6. **Aprendizaje.** Predicción y actualización de Kalman de μ_t y, después, actualización EWMA de la varianza.

$$
\begin{aligned}
\mu_t &= \mu_{t-1} + w_t, \quad w_t \sim N(0, Q), \quad Q = 10^{-10} \\
y_t = S_t - \phi S_{t-1} &= (1-\phi)\,\mu_t + e_t, \quad e_t \sim N(0, R) \\
\sigma^2_{e,t} &= \lambda\, \sigma^2_{e,t-1} + (1-\lambda)\, e_t^2, \qquad
\hat\sigma_t = \sqrt{\sigma^2_{e,t} / (1-\phi^2)}
\end{aligned}
$$

$$
\begin{aligned}
P_{t|t-1} &= P_{t-1|t-1} + Q, & e_t &= y_t - (1-\phi)\,\hat\mu_{t|t-1}, & S_t
&= (1-\phi)^2 P_{t|t-1} + R \\
K_t &= \frac{P_{t|t-1}(1-\phi)}{S_t}, & \hat\mu_{t|t} &= \hat\mu_{t|t-1} +
K_t e_t, & z_t &= \frac{S^{spread}_t - \hat\mu_{t|t-1}}{\hat\sigma_{t|t-1}}
\end{aligned}
$$

5.2 Los 5 elementos del modelo

Elemento	Filtro 2
Variable de estado	Creencia: media latente estimada, su varianza y la varianza EWMA de las innovaciones
Variable de decisión	El z-score con estadísticos prior, que alimenta la regla de trading
Información exógena	El spread del día siguiente, que llega del filtro 1

Elemento	Filtro 2
Función de transición	Predicción y actualización de la media latente, y EWMA de la varianza
Función objetivo	Máxima verosimilitud de las innovaciones en entrenamiento, con la que se elige Q; las innovaciones normalizadas deben ser ruido blanco con varianza 1

5.3 Ganancia de Kalman

El 26 de septiembre de 2022 la varianza prior de μ era 1.1167×10^{-5} y $1 - \varphi = 0.0437$. La varianza de la innovación fue $0.0437^2 \times 1.1167 \times 10^{-5} + 6.515 \times 10^{-5} = 6.517 \times 10^{-5}$, y la ganancia **$K = 1.1167 \times 10^{-5} \times 0.0437 / 6.517 \times 10^{-5} = 0.00749$**.

La innovación de ese día fue −0.0164, así que la media latente bajó apenas $0.00749 \times (-0.0164) = -0.00012$, de 1.91624 a 1.91612. El filtro trata la caída del spread como una desviación del equilibrio y no como un cambio del equilibrio; por eso el z-score cruzó −2 y se generó la señal. La ganancia decrece con el tiempo (figura 5): con una Q tan pequeña, cada día el filtro confía más en lo que ya sabe sobre μ.

5.4 Selección de Q y R

- **φ y R:** AR(1) ajustado por OLS sobre el spread del filtro 1 en entrenamiento, después del burn-in: $\varphi = 0.9563$ y $R = 6.515 \times 10^{-5}$, la varianza de los residuales.
- **Q por máxima verosimilitud** en entrenamiento. Aquí sí es válido, a diferencia del filtro 1, porque el modelo incluye la reversión AR(1) del spread. La verosimilitud es casi plana para $Q \leqslant 10^{-8}$ y cae para Q mayores; se elige el máximo, $Q = 10^{-10}$.

Q	10^{-10}	10^{-9}	10^{-8}	10^{-7}	10^{-6}	10^{-5}
Log-verosimilitud	**7483.50**	7483.49	7483.39	7482.66	7480.14	7474.40

- **$\lambda = 0.97$** en el EWMA de la varianza: una vida media de unas 23 sesiones, comparable a la del spread.
- **Inicialización:** $\hat{\mu}_0$ = media del spread de entrenamiento y varianza inicial 10^{-4}.

5.5 Diagnóstico de las innovaciones (prueba 4)

Si el modelo está bien especificado, las innovaciones normalizadas deben tener varianza cercana a 1 y no estar autocorrelacionadas. La prueba `tests/test_filter.py` lo verifica.

Partición	Observaciones	Varianza	Autocorrelación de orden 1	Banda al 95%	Ljung-Box p
Entrenamiento	2,202	1.09	−0.014	±0.043	0.008
Prueba	754	0.99	0.022	±0.073	0.975
Validación	755	1.08	−0.045	±0.073	0.374

Fuera de muestra el modelo pasa sin reservas. En entrenamiento Ljung-Box rechaza (p = 0.008) por la volatilidad de marzo de 2020; la autocorrelación de orden 1 queda dentro de su banda en las tres particiones.

5.6 Ejemplo numérico (mismos días)

Fecha	Spread	Media prior	Dispersión prior	z-score	Innovación	Ganancia K	Media posterior
22-sep-2022	1.88743	1.91626	0.02155	−1.34	0.00068	0.007494	1.91627
23-sep-2022	1.88537	1.91627	0.02123	−1.46	−0.00332	0.007492	1.91624
26-sep-2022	1.87028	1.91624	0.02100	**−2.19**	−0.01644	0.007490	1.91612
27-sep-2022	1.86379	1.91612	0.02286	**−2.29**	−0.00849	0.007487	1.91606
28-sep-2022	1.87396	1.91606	0.02307	−1.82	0.00788	0.007485	1.91611

El z-score del 26 de septiembre es (1.87028 − 1.91624) / 0.02100 = −2.19. Con z de entrada = 2.0 se activa la señal larga en el spread: comprar DUK y SO, vender AEP y XEL. La orden se ejecuta al cierre del día siguiente, y en efecto la bitácora registra una entrada larga el 27 de septiembre de 2022, que cerró con ganancia el 14 de diciembre. La ganancia calculada a mano coincide con la del filtro en todos los días (error de 10^{-10}).

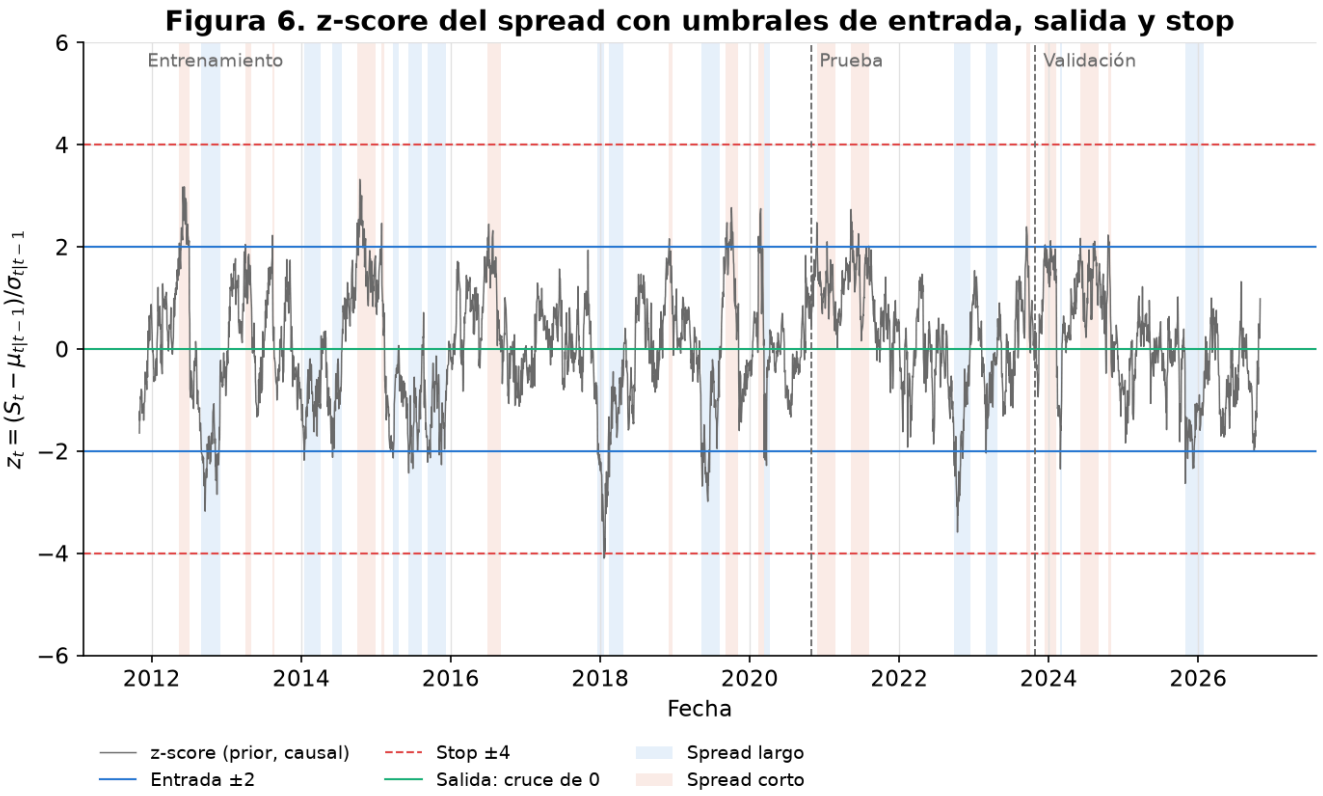


Figura 6. z-score prior del filtro 2 con los umbrales elegidos en entrenamiento (entrada ±2, salida al cruzar 0, stop ±4); sombreados los días con posición abierta.

6. Estabilidad de la relación

La relación no se rompió de golpe, pero se debilitó: con los pesos fijos de Johansen el spread deja de ser estacionario en validación, y con los pesos del filtro 1 sigue siéndolo en las tres particiones.

6.1 Spread con pesos fijos contra spread de Kalman

Spread	Partición	ADF p	Vida media (días)	¿Estacionario al 5%?
Pesos fijos de Johansen	Entrenamiento	0.0002	24.0	Sí
Pesos fijos de Johansen	Prueba	0.0034	29.8	Sí
Pesos fijos de Johansen	Validación	0.0543	40.5	**No**
Pesos de Kalman (filtro 1)	Entrenamiento	< 0.0001	15.9	Sí

Spread	Partición	ADF p	Vida media (días)	¿Estacionario al 5%?
Pesos de Kalman (filtro 1)	Prueba	0.0109	22.9	Sí
Pesos de Kalman (filtro 1)	Validación	0.0019	17.0	Sí

Con pesos fijos la reversión es cada vez más lenta (24 → 30 → 40 días) hasta dejar de ser significativa. Con los pesos de Kalman la vida media se mantiene entre 16 y 23 días. El filtro lo logra ajustando los pesos poco a poco, no saltando:

Fecha	β_SO	β_AEP	β_XEL
Johansen (entrenamiento)	0.181	−0.614	−0.099
28-oct-2020 (inicio de prueba)	0.177	−0.613	−0.098
27-oct-2023 (inicio de validación)	0.154	−0.626	−0.112
30-oct-2026 (fin de la muestra)	0.141	−0.628	−0.113

El peso de SO baja de 0.177 a 0.141 (−20%) entre 2020 y 2026 y los de AEP y XEL se vuelven algo más negativos. Es la deriva lenta que el filtro 1 está diseñado para seguir, y la razón de que la estrategia opere el spread de Kalman y no el de Johansen.

6.2 Johansen móvil

Se repitió la prueba de Johansen en ventanas de tres años (756 días) que avanzan un mes (21 días), en toda la muestra. La figura 4 muestra el primer eigenvector normalizado de cada ventana.

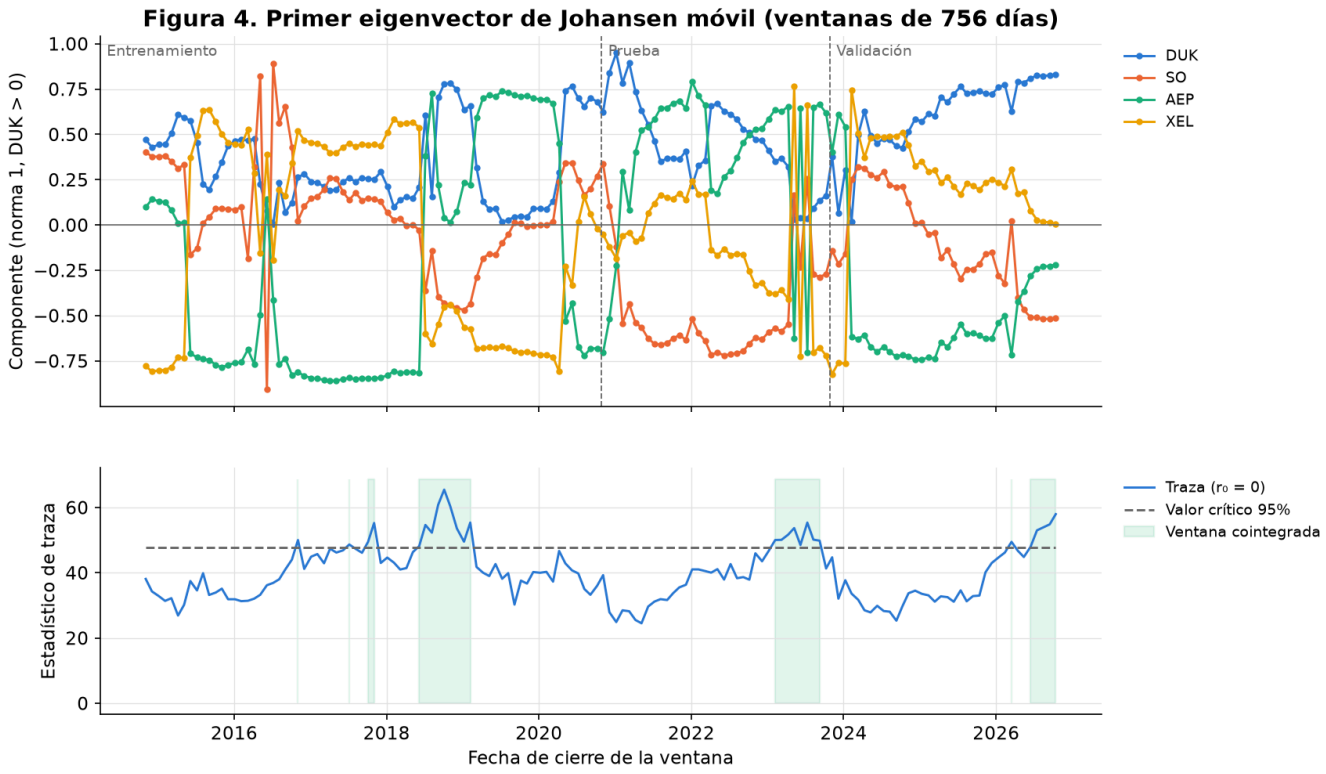


Figura 4. Componentes del primer eigenvector de Johansen en ventanas móviles de tres años, normalizado sobre DUK.

- Solo **19% de las ventanas** rechaza la ausencia de cointegración al 95%.
- Las ventanas que sí cointegran se concentran en 2017–2018 (25% y 58% de las ventanas de esos años), 2023 (67%) y 2026 (60%).
- En 2014–2015, en 2020–2022 (COVID, inflación y subida de tasas) y en 2024–2025 ninguna ventana cointegra.
- El eigenvector no es estable: el componente de AEP va de −0.85 (2017) a +0.62 (2019), y el de SO cambia de signo varias veces.

Interpretación. Con tres años de datos la prueba de Johansen tiene poco poder: no rechazar no demuestra que la relación no exista, y la prueba sobre los nueve años de entrenamiento sí la detecta. Aun así, la evidencia no es la de una relación estructural fuerte. La relación es débil, intermitente y desaparece en los episodios de choques de tasas, cuando cada utility reacciona según su propia estructura de deuda y regulación.

6.3 Cómo se refleja en la estrategia

La estrategia pierde dinero cuando una posición deja de revertir, y eso coincide con los periodos sin cointegración. Fuera de muestra no hubo ningún stop; hubo cuatro salidas por tiempo máximo (63 días) y tres de ellas cerraron con pérdida: −$14,598 (mayo a agosto de 2021), −$21,939 (junio a septiembre de 2024) y −$15,282 (octubre de 2025 a febrero de

2026). Las tres caen en meses en que ninguna ventana del Johansen móvil detecta cointegración. La tenencia máxima funcionó como límite: sin ella esas posiciones habrían seguido abiertas.

7. VECM y reglas de señal

Sección a cargo de Raúl. Contenido mínimo (fuentes: `artifacts/vecm.json`, `strategy/`, supuestos del README):

- [ ] VECM con el vector de Johansen fijo como término de corrección de error: tabla de α por activo con su estadístico t (DUK −0.0276, t = −3.61; SO −0.0305, t = −3.84; AEP −0.0091, t = −1.18; XEL −0.0164, t = −2.16) e interpretación: DUK y SO corrigen, AEP no se ajusta (funciona como ancla).
- [ ] Condición de estabilidad $-2 < \beta^T\alpha < 0$ ($\beta^T\alpha = -0.026$) y vida media implícita de 26.4 días.
- [ ] Por qué la señal usa el z-score del filtro 2 (indicación del profesor: los residuales normalizados son la salida del filtro 2).
- [ ] Reglas: entrada, salida (con la extensión de cruce de banda y su razón), stop en $|z| = 4$, tenencia máxima en múltiplos de la vida media de 15.5 días, re-armado después de un stop o de una salida por tiempo.
- [ ] Sizing: $N_i = 0.8 \cdot V \cdot \hat{\beta}_i / \Sigma|\hat{\beta}_j|$, signo según la dirección; acciones fraccionarias.
- [ ] Figura 2: spread con las señales de entrada y salida marcadas.

8. Backtest, costos y calibración

Sección a cargo de Raúl. Contenido mínimo (fuentes: `backtest/`, `artifacts/grid_search.csv`, `artifacts/q_sensitivity.csv`, supuestos del README):

- [ ] Motor multi-pata: efectivo + valor de las patas; ejecución al cierre de t de la decisión de t − 1; comisión de 0.125% por pata en entradas, salidas y rebalanceos; préstamo de 0.25% anual sobre el nocional corto.
- [ ] Prueba de contabilidad multi-pata (`tests/test_accounting.py`): qué verifica.
- [ ] Grid search en entrenamiento: valores probados (72 combinaciones), criterio (Sharpe neto), mínimo de 15 operaciones y por qué; combinación elegida (z de entrada 2.0, z de salida 0, tenencia de 4 vidas medias = 63 días).
- [ ] Figura A1 (robustez del grid) y su lectura: z de salida = 0 es la mejor columna en todos los paneles.
- [ ] Por qué Q del filtro 1 no entra al grid: tabla de `q_sensitivity.csv` (10^{-9} gana en entrenamiento con 0.70 y cae a 0.20 en prueba).
- [ ] Walk-forward: una sola corrida continua con parámetros congelados.

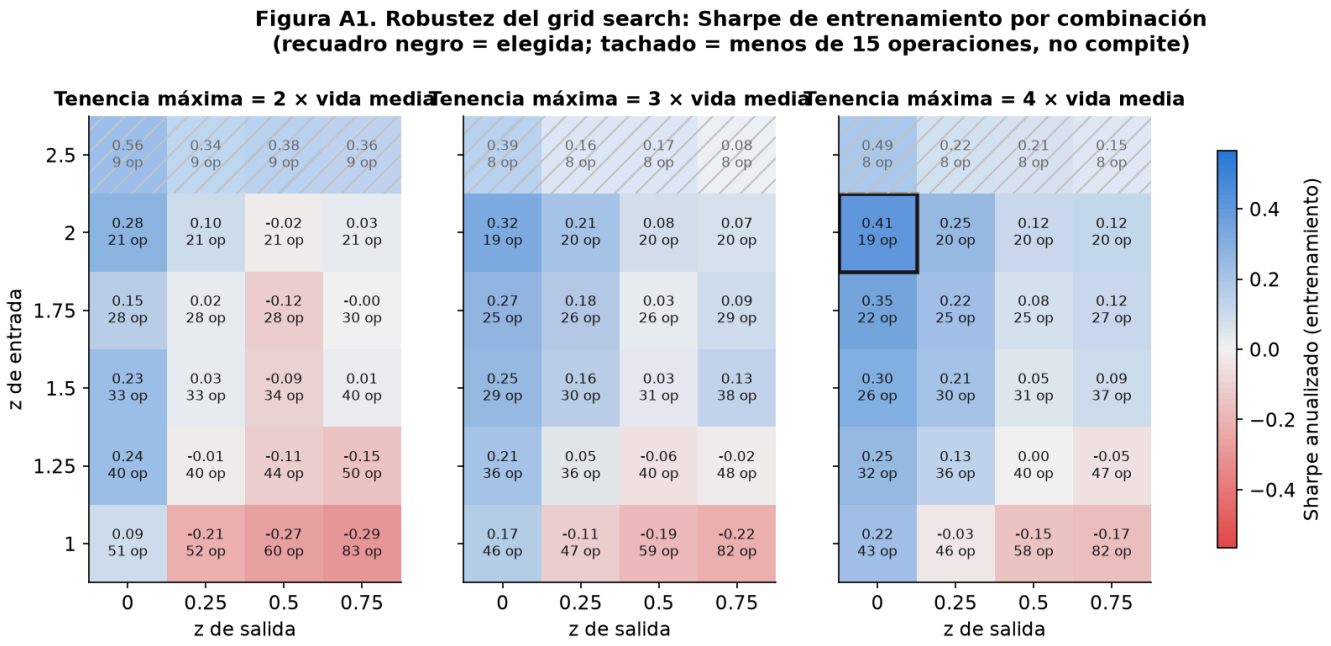


Figura A1. Sharpe de entrenamiento de las 72 combinaciones del grid; recuadro = combinación elegida, tachado = menos de 15 operaciones.

9. Resultados

Sección a cargo de Raúl. Contenido mínimo (fuentes: `artifacts/metrics.json`, `trades.csv`, `rebalancing.csv`, `equity.csv`):

- [ ] Tabla por partición: rendimiento, rendimiento anual, volatilidad, Sharpe, Sortino, Calmar, drawdown máximo, operaciones, win rate y profit factor (entrenamiento 0.41 / prueba 0.32 / validación 0.30 de Sharpe).
- [ ] Atribución de costos: P&L bruto → comisiones → préstamo → P&L neto (las comisiones consumen 26% de la ganancia bruta total; 23%, 31% y 36% por partición).
- [ ] Rebalanceo diario contra bandas de 2%, 5% y 10% y sin rebalanceo: costo y exposición de cada política, y por qué se mantiene el diario aunque la banda de 10% dé mejor Sharpe.
- [ ] Bitácora: causas de salida (29 operaciones: 20 por reversión, 1 stop y 8 por tiempo) y las peores operaciones.
- [ ] Sharpe móvil de 252 días y su lectura.
- [ ] Figura 7 (curvas de capital por partición con drawdown) y figura 8 (distribución de retornos por operación con normal superpuesta).

10. El sistema completo como un proceso de decisión secuencial

Sección a cargo de Raúl. Contenido mínimo (sección 3.5 de los lineamientos):

- [ ] Los 6 pasos de Powell para el sistema completo: filtros 1 y 2, VECM y lógica de trading como un solo proceso.
- [ ] Los 5 elementos, con el estado separado explícitamente en físico (efectivo, acciones de cada activo, dirección de la posición, días en posición), de información (precios, spread, z-score) y de creencia (filtro 1, filtro 2, vector de Johansen, parámetros del VECM).
- [ ] Variable de decisión (dirección y número de acciones por activo), información exógena, función de transición (filtros + contabilidad) y función objetivo (Sharpe neto en entrenamiento, con θ = umbrales y tenencia máxima).
- [ ] Ejemplo numérico de varios días: se sugiere continuar el del 26 al 28 de septiembre de 2022 (señal el 26, entrada larga el 27), mostrando efectivo, acciones por activo y valor del portafolio día por día.

11. ¿Estructural o artefacto? Conclusiones y limitaciones

Nuestra respuesta: la relación tiene una base económica real, pero es débil y cambia con el tiempo; no es un artefacto de las pruebas múltiples, y tampoco es una relación estructural firme.

11.1 Lo que el trabajo demuestra

- **No es un falso positivo aislado.** Los cinco grupos aprobados de 66 están en un solo sector y comparten activos; en los otros cinco sectores no aprobó ninguno de 55 (sección 3.4).
- **La relación sobrevive fuera de muestra si los pesos se adaptan.** El spread de Kalman es estacionario en prueba y validación; el de pesos fijos no lo es en validación (sección 6.1).
- **No hay sobreajuste de parámetros.** Solo se optimizaron tres parámetros, solo en entrenamiento; el Sharpe baja de 0.41 a 0.32 y 0.30 sin colapsar, y la combinación elegida está en una zona estable del grid (figura A1). El único sobreajuste que encontramos, incluir Q del filtro 1 en el grid, se detectó y se descartó.
- **Los filtros están bien especificados fuera de muestra.** Las innovaciones normalizadas del filtro 2 tienen varianza 0.99 y 1.08 y no están autocorrelacionadas (sección 5.5).

11.2 Lo que el modelo supone y no demuestra

- Que la relación de largo plazo existe durante toda la muestra. El Johansen móvil solo la detecta en 19% de las ventanas de tres años y el eigenvector cambia de signo (sección 6.2).

- Ruidos gaussianos e independientes en ambos filtros, y un spread que revierte como AR(1) con φ constante.
- Ejecución al precio de cierre, con acciones fraccionarias, sin impacto de mercado ni restricciones para tomar prestado.

11.3 Limitaciones

1. **Significancia estadística.** Con 5 operaciones en prueba y 5 en validación, un Sharpe de 0.3 en tres años tiene un error estándar de alrededor de 0.58: no se distingue de cero. En los 15 años completos, el Sharpe de 0.37 da un estadístico t de alrededor de 1.4, tampoco significativo al 5%.
2. **Rendimiento económico.** El 1.3% anual (0.9% en prueba y 0.7% en validación) está por debajo de la tasa de los bonos del Tesoro de corto plazo en 2023–2026; el Sharpe reportado supone tasa libre de riesgo cero. La posición está abierta solo alrededor de 30% de los días.
3. **Costos.** Las comisiones consumen 26% de la ganancia bruta, y su peso crece fuera de muestra (31% y 36%). Bajar el umbral de entrada aumenta las operaciones pero reduce el Sharpe neto.
4. **Sesgo de selección del universo.** El sector se eligió después de ver que las petroleras no cointegraban. Todo se hizo con datos de entrenamiento y se reportan los 66 grupos, pero la elección del sector también es una prueba más.
5. **Riesgo de ruptura.** Las pérdidas fuera de muestra vinieron de posiciones que dejaron de revertir en meses sin cointegración. La tenencia máxima las limitó, pero no hay un mecanismo que detecte la ruptura antes de entrar.

11.4 Qué haríamos distinto en producción

- Condicionar la entrada a una prueba de cointegración móvil o a la estabilidad de la vida media, para no abrir posiciones en periodos sin relación.
- Usar una banda de no-rebalanceo calibrada en entrenamiento y no a posteriori.
- Operar varios grupos independientes (Nivel B) para tener más operaciones y diversificar el riesgo de ruptura de una sola relación.
- Medir el desempeño contra la tasa libre de riesgo y con costos de ejecución realistas.

12. Reproducibilidad y uso de IA

Todo el trabajo se reproduce con un comando desde el repositorio Lab03_MyST_Equipo7, con semilla 42 fijada en `config.py` y dependencias con versiones fijadas en `requirements.txt` (Python 3.12).

```
pip install -r requirements.txt
python main.py                  # pipeline completo; escribe artifacts/ y
docs/figures/
pytest                          # 4 pruebas obligatorias (10 casos)
streamlit run dashboard/app.py  # dashboard; solo lee artifacts/
```

Prueba (sección 3.11)	Archivo	Qué verifica
Causalidad	`tests/test_causality.py`	El z-score en t no cambia al recalcular el pipeline solo con datos hasta t, en tres fechas
Normalización	`tests/test_normalization.py`	El peso de DUK se mantiene en +1 y los demás conservan escala y signo entre reestimaciones
Contabilidad multi-pata	`tests/test_accounting.py`	Valor = efectivo + patas; costo total = comisiones por pata + devengo del préstamo
Filtro	`tests/test_filter.py`	Innovaciones normalizadas con varianza cercana a 1 y sin autocorrelación significativa

Uso de IA. Se usó Claude (Anthropic) como asistente de programación y de redacción: estructura de los módulos, revisión de código, verificación independiente de resultados y borradores de documentación y de este reporte. Las decisiones de diseño (universo, normalización, Q fija del filtro 1, reglas de señal, criterio del grid) son del equipo, y cada integrante puede explicar cualquier línea del código. El detalle está en la sección "Uso de herramientas de IA" del README.